



Infraestrutura de TI com IA

Produtividade aumentada por agentes, multimodelo e harness loop

Documento Executivo

Infraestrutura de TI com IA em Google Cloud — versão econômica

Sem Vertex AI · apoiada em Claude Pro/Max + Gemini Business já contratados

VERSÃO

1.0

DATA

Junho / 2026

CLASSIFICAÇÃO

Uso interno

Sumário Executivo

Esta é a versão enxuta e econômica da infraestrutura de TI com IA da setup.com.br. A infraestrutura roda em Google Cloud e Google Workspace, mas a camada de modelos — que era o maior custo na versão com Vertex AI, por ser cobrada por token — passa a se apoiar em assinaturas de valor fixo que a empresa já paga: Claude Pro/Max e Gemini Business.

O resultado é a mesma capacidade da arquitetura original ao menor custo incremental possível: a Vertex AI é eliminada, os modelos viram custo fixo já contratado e a infraestrutura de apoio cabe majoritariamente no free tier permanente do Google Cloud.

Em números: o gasto incremental da Operação (50 usuários) cai de ~US\$ 1.150 para ~US\$ 280/mês (–75%); o Piloto (10 usuários) fica praticamente em R\$ 0, coberto pelo free tier.

Arquitetura de TI com IA — visão em camadas

EXPERIÊNCIA

PC · Notebook · Tablet · Smartphone · WhatsApp · Chat/IDE

Onde o profissional interage — a mesma IA em cada tela



ORQUESTRAÇÃO — “o cérebro”

Roteador multimodelo · Harness loop · Memória · Catálogo de agentes

Decide o modelo, conduz o ciclo e mantém o contexto



FERRAMENTAS / CONECTORES (MCP)

WhatsApp · Google Workspace · GitHub · computer-use · Sistemas internos (Projetos/Contratos/Comercial)

A “tomada universal” que liga a IA aos sistemas reais



DADOS E GOVERNANÇA

SSO Google · Cofre de segredos · Auditoria · DLP · Backup

Segurança, permissões mínimas e conformidade por padrão

Figura 1 — A infraestrutura em quatro camadas integradas.

1 Princípios de economia

A estratégia de custo se apoia em reaproveitar o que já está contratado e usar os free tiers permanentes do Google Cloud:

- **Não recomprar o que já existe** — Workspace, Gemini Business, Claude Pro/Max, WhatsApp (Meta), GitHub, host próprio e sistemas internos já estão pagos.
- **Modelos por assinatura fixa, não por token** — Claude Pro/Max para o trabalho agêntico e Gemini Business para a produtividade no Workspace. Vertex AI eliminada.
- **Free tier primeiro** — Cloud Run, Pub/Sub, Firestore, Logging e Firebase cabem majoritariamente no free tier permanente.
- **Reuso do host próprio** — computer-use, transcrição de áudio (Whisper) e embeddings para RAG rodam no servidor que já existe.
- **Governança por padrão** — identidade única, permissões mínimas, auditoria e DLP usando recursos já inclusos no Workspace.

2 Como cada peça da Vertex AI é substituída

O que a Vertex fazia	Alternativa sem Vertex (já contratada / grátis)
Modelos do cérebro (Pro/Flash/Lite)	Claude Pro/Max dirige o harness loop via Claude Code.
IA para usuário final	Gemini Business no Workspace (Gmail/Docs/Sheets/Meet) + app Gemini.
RAG / Vector Search	NotebookLM (no Gemini Business) + pgvector com embeddings open-source no host.
Speech-to-Text (áudio WhatsApp)	Whisper (open-source) no host próprio, ou app Gemini.
Document AI (OCR)	OCR nativo do Google Drive/Docs (grátis) ou Tesseract no host.
Agentes especializados	Gems (Gemini Business) + sub-agentes do Claude Code.

Trade-off honesto: assinaturas têm limites por seat/uso — atendem bem Piloto e Operação; em escala muito alta de automação backend pode ser preciso mais seats Max ou um fallback metered pontual.

3 Serviços — contratar vs. reaproveitar

Já contratados (reaproveitar, US\$ 0 incremental)

- **Google Workspace + Gemini Business** — e-mail, Docs, Sheets, Meet, Drive, SSO, Gemini nas apps, Gems, NotebookLM, Vault e DLP.
- **Claude Pro/Max** — runtime dos agentes via Claude Code.
- **WhatsApp Meta Cloud API** — canal de atendimento de produção.
- **GitHub** — DevOps e chamados de engenharia.
- **Host próprio** — computer-use, Whisper, embeddings e sistemas internos.

A ativar no Google Cloud (majoritariamente free tier)

Serviço	Para quê	Custo
Cloud Run	MCP servers + webhook WhatsApp	free → baixo
Pub/Sub + Cloud Tasks	Orquestração do loop	free tier
Firestore	Estado de sessão/agentes	free → baixo
Cloud Storage	Backup de artefatos	baixo
Secret Manager	Chaves e tokens	~US\$ 0
Cloud Identity + IAP	SSO e acesso seguro	incluído / US\$ 0
Cloud Logging/Monitoring	Observabilidade	free tier
Looker Studio	Painéis de indicadores	grátis
Firebase Hosting/Auth/FCM	PWA mobile/tablet + push	Spark grátis

4 Plano de implantação passo a passo (com custo)

Custos incrementais mensais no Google Cloud (US\$ 1 ≈ R\$ 5,50), cenário de referência Operação (50 usuários). O esforço de engenharia é interno (agente DevOps + Claude Code), não vira assinatura.

Fase 0 — Fundação (semana 1)

- **Passo 1** — Projeto GCP + Billing + organização. Google Cloud · US\$ 0 (crédito inicial US\$ 300).
- **Passo 2** — SSO, grupos, MDM. Cloud Identity (Workspace já pago) · US\$ 0.
- **Passo 3** — Migrar .env para cofre. Secret Manager · ~US\$ 0.

Fase 1 — Camada de IA nas assinaturas (semana 1-2)

- **Passo 4** — Harness loop + agentes via Claude Code. Claude Pro/Max · US\$ 0 incremental.
- **Passo 5** — Gemini no Workspace + Gems + NotebookLM. Gemini Business · US\$ 0 incremental.

Fase 2 — Conectores MCP em produção (semana 2-4)

- **Passo 6** — Containerizar MCP (WhatsApp, Gmail, Calendar, Drive, GitHub). Cloud Run · US\$ 0-50.
- **Passo 7** — Webhook WhatsApp (Meta já paga) em fila de eventos. Cloud Run + Pub/Sub · US\$ 0-20.
- **Passo 8** — computer-use no servidor existente. Host próprio · US\$ 0.

Fase 3 — Memória e RAG sem Vertex (semana 4-6)

- **Passo 9** — Q&A nos documentos do Drive. NotebookLM · US\$ 0.
- **Passo 10** — RAG programático com embeddings OSS. pgvector no host · US\$ 0 (ou Cloud SQL ~US\$ 50).
- **Passo 11** — Áudio→texto e OCR. Whisper OSS + OCR do Drive · US\$ 0.

Fase 4 — Estado e dados (semana 5-6)

- **Passo 12** — Estado de sessão/agentes. Firestore · US\$ 0-30.
- **Passo 13** — Exportar sistemas internos como MCP. Onde já rodam · US\$ 0 incremental.
- **Passo 14** — Backup dos artefatos (Drive = fonte da verdade). Cloud Storage · US\$ 5-30.

Fase 5 — Governança e observabilidade (semana 6-7)

- **Passo 15** — Acesso seguro. IAP (US\$ 0) + Cloud Armor · US\$ 0-20.
- **Passo 16** — Trilha de auditoria do loop. Cloud Audit Logs · US\$ 0-20.
- **Passo 17** — Retenção/DLP. Vault + DLP do Workspace · US\$ 0 incremental.
- **Passo 18** — Logs/métricas + painéis. Cloud Logging/Monitoring + Looker Studio · US\$ 0-20.

Fase 6 — Experiência multidispositivo (semana 7-8)

- **Passo 19** — PWA com login Workspace + push. Firebase Hosting/Auth/FCM · US\$ 0-10.

Fase 7 — Otimização contínua (mês 3+)

- **Passo 20** — Roteamento (Gems vs Claude), Committed Use Discounts (–20% a –55%), limpeza de logs. Efeito: reduz custo.

5 Custo acumulado e estimativa por cenário

Acumulado por fase — Operação (50 usuários)

Acumulado até...	Incremental/mês (US\$)	(R\$)
Fase 1 (IA no ar)	~0	~R\$ 0
Fase 2 (conectores)	~0-70	~R\$ 0-385
Fase 3 (RAG)	~0-120	~R\$ 0-660
Fase 4 (dados)	~5-180	~R\$ 30-990
Fase 5 (governança)	~5-240	~R\$ 30-1.320
Fase 6 (completo)	~5-250	~R\$ 30-1.375

Por cenário (gasto incremental, sem Vertex)

Cenário	Usuários	Com Vertex (US\$)	Sem Vertex (US\$)	Sem Vertex (R\$)
Piloto	10	~450	~150	~R\$ 800
Operação	50	~1.150	~280	~R\$ 1.550
Escala	150	~3.200	~900	~R\$ 4.950

Resultado: eliminar a Vertex e apoiar a IA em Claude Pro + Gemini Business derruba o incremental da Operação em 75%. O Piloto fica praticamente em R\$ 0, coberto pelo free tier permanente do Google Cloud.

Valores aproximados (referência Google Cloud/Workspace início de 2026; sujeitos a câmbio e tabela vigente). O custo só sobe de forma relevante se o volume de automação backend ultrapassar os limites das assinaturas.

Em uma frase
possível — modelos já pagos, infraestrutura no free tier e governança por padrão.